Contents

1	概述	
•	1.1	统计学习三要素....................................
	1.1	1.1.1 模型
		1.1.2 策略
		1.1.3 算法
	1.2	模型评估与模型选择
	1	1.2.1 训练误差与测试误差
		1.2.2 过拟合与模型选择
	1.3	正则化与交叉验证
	1.0	1.3.1 正则化
		1.3.2 交叉验证
	1.4	泛化能力
		1.4.1 泛化误差
		1.4.2 泛化误差上界
	1.5	生成模型与判别模型....................................
	1.6	分类问题
	1.7	标注问题
	1.8	回归问题
2	感知机	Л
•	1 15	NT N-L
3	k 近邻	沙法
4	朴素贝	八叶斯法
	4.1	贝叶斯公式
	4.2	极大似然估计 (MLE)
	4.3	最大后验估计 (MAP)
	4.4	贝叶斯估计
5	决策标	对
6	logist	tic 回归与最大熵模型
•	-08-0	
7	支持向	可量机
0	+B 1L →	F2+
8	提升力	
	8.1	gbdt
		8.1.2 gbdt 的负梯度拟合
		6.1.2 gout 的贝彻皮拟目 · · · · · · · · · · · · · · · · · · ·
9	EM 🦸	算法及其推广
10	隐马尔	下可夫模型 第一章
11	条件隊	道机场
12	ᄱᅩᆿ	
12	附录 12.1	to the
		矩阵
	12.2	优化
		12.2.1 拉格朗日乘子法
		12.2.2 梯度下降
		12.2.4 拟牛顿法的思路
		12.2.5 DFP(Davidon-Fletcher-Powell)
		12.2.0 D11 (Dw/14011 1000101 10001)

	12.2.6 BFGS(Broydon-Fletcher-Goldfarb-Shanno)
	拉格朗日对偶性
12.4	信息论相关
	12.4.1 凸集
	12.4.2 凸函数
	12.4.3 KL 散度
12.5	采样
	12.5.1 拒绝采样
	12.5.2 重要性采样
	12.5.3 马尔可夫蒙特卡洛采样(MCMC)

本文参考自李航的《统计学习方法》、周志华的《机器学习》、Hulu 的《百面机器学习》等。

1 概述

1.1 统计学习三要素

1.1.1 模型

监督学习中,模型是要学习的条件概率分布或决策函数。

1.1.1.1 模型的假设空间

假设空间是所有可能的条件概率分布或决策函数

1.1.1.1.1 定义 1

可以定义为**决策函数的集合**:

$$\mathcal{F} = \{ f | Y = f(X) \}$$

- X 和 Y 是定义在 $\mathcal X$ 和 $\mathcal Y$ 上的变量
- \mathcal{F} 是一个参数向量决定的**函数族**:

$$\mathcal{F} = \{ f | Y = f_{\theta}(X), \theta \in \mathbb{R}^n \}$$

参数向量 heta 取值于 $\mathbf n$ 维欧式空间 R^n ,称为**参数空间**

1.1.1.1.2 定义 2

也可以定义为条件概率的集合:

$$\mathcal{F} = \{P|P(Y|X)\}$$

- X 和 Y 是定义在 $\mathcal X$ 和 $\mathcal Y$ 上的随机变量
- \mathcal{F} 是一个参数向量决定的**条件概率分布族**:

$$\mathcal{F} = \{P|P_{\theta}(Y|X), \theta \in \mathbb{R}^n\}$$

1.1.2 策略

1.1.2.1 损失函数与风险函数

损失函数(loss function)或代价函数(cost function): 度量预测值 f(X) 与真实值 Y 的误差程度,记为 L(Y,f(X)),是个非负实值函数。损失函数越小,模型越好。

• 0-1 损失函数:

$$L(Y, f(X)) = \begin{cases} 0 & Y \neq f(X) \\ 1 & Y = f(X) \end{cases}$$

• 平方损失函数:

$$L(Y, f(X)) = (Y - f(X))^2$$

• 绝对损失函数:

$$L(Y, f(x)) = |Y - f(X)|$$

• 对数损失函数 (logarithmic loss function)/对数似然损失函数 (log-likelihood loss function):

$$L(Y, P(Y|X)) = -logP(Y|X)$$

风险函数 (risk function) 或期望损失 (expected loss): X 和 Y 服从联合分布 P(X,Y), 理论上模型 f(X) 关于联合分布 P(X,Y) 的平均意义下的损失:

$$R_{exp}(f) = E_P[L(Y, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(y, f(x)) P(x, y) dx dy$$

学习的目标:选择期望风险最小的模型。但联合分布 P(X,Y) 是未知的,所以无法直接计算 $R_{exp}(f)$ 。所以监督学习是病态问题(ill-formed problem):一方面需要联合分布,另一方面联合分布是未知的。

给定训练集:

$$T = \{(x_1, y_1), ...(x_N, y_N)\}\$$

经验风险 (expirical risk)/经验损失 (expirical loss): 模型 f(X) 关于训练集的平均损失

$$R_{emp}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i))$$

根据**大数定律**,当样本容量 N 趋向无穷时,经验风险 R_{emp} 趋于期望风险 $R_{exp}(f)$ 。

1.1.2.2 经验风险最小化与结构风险最小化

经验风险最小化(empirical risk minimization, ERM): 经验风险最小的模型就是最优模型。所以需要求解的最优化问题是:

$$\min_{f \in \mathcal{F}} R_{erm} = \min_{f \in \mathcal{F}} \frac{1}{N} L(y_i, f(x_i))$$

当满足以下两个条件时,经验风险最小化就等价于极大似然估计(maximum likelihood estimation):

• 模型是条件概率分布

• 损失函数是对数损失函数

当样本量足够大时,ERM 能有很好的效果,但样本量不够多时,为了防止过拟合,需要用下面的方法。

结构风险最小化(structual risk minimization, SRM):结构风险 = 经验风险 + 表示模型复杂度的正则化项 (regularizer)或罚项 (penalty term)。结构风险定义如下:

$$R_{srm}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

J(f) 是模型的复杂度,模型越复杂,J(f) 越大。 $\lambda \geq 0$ 是用于权衡经验风险和模型复杂度的系数。

当满足以下 3 个条件时,结构化风险最小化等价于) 贝叶斯估计中的最大后验概率估计 (maximum posterior probability estimation, MAP):

- 模型是条件概率分布
- 损失函数是对数损失函数,对应后验估计中的似然函数
- 模型复杂度由模型的先验概率表示

似然函数和先验概率的乘积即对应贝叶斯最大后验估计的形式

参考https://www.zhihu.com/question/23536142

所以结构风险最小化就是求解优化问题:

$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

1.1.3 算法

算法指的是学习模型的具体方法,即使用什么计算方法求解最优模型。

因为统计学习问题归结为最优化问题,所以统计学习的算法就是求解最优化问题的算法。

- 如果有显式的解析解,此最优化问题就比较简单
- 如果没有,需要用数值计算方法求解,需要考虑如何**保证找到全局最优解,并使求解过程高效**

1.2 模型评估与模型选择

1.2.1 训练误差与测试误差

假设学习到的模型是 $Y=\hat{f}(X)$,训练误差是模型 $Y=\hat{f}(X)$ 关于训练数据集的平均损失(N 是样本容量):

$$R_{emp}(\hat{f}) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, \hat{f}(x_i))$$

测试误差是模型 $Y=\hat{f}(X)$ 关于测试数据集的平均损失(N' 是测试样本容量):

$$e_{test}(\hat{f}) = \frac{1}{N'} \sum_{i=1}^{N'} L(y_i, \hat{f}(x_i))$$

- 训练误差的大小,对判断给定的问题是不是一个容易学习的问题是有意义的
- 测试误差反映了学习方法对未知数据的预测能力,即泛化能力(generalization ability)

1.2.2 过拟合与模型选择

当模型复杂度增加时,训练误差会逐渐减小并趋向于0;测试误差会先减小,达到最小值后又会增大。

当模型复杂度过大时,就会出现过拟合。所以需要在学习时防止过拟合,选择复杂度适当的模型。

1.3 正则化与交叉验证

1.3.1 正则化

模型选择的典型方法是正则化(regularization)。正则化是**结构风险最小化**策略的实现,即在经验上加一个正则化项(regularizer)或罚项(penalty term)。

正则化项一般是**模型复杂度的单调递增函数**,模型越复杂,正则化值越大。比如,正则化项可以是模型参数向量的范数。

$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

其中 $\lambda \geq 0$

正则化符合奥卡姆剃刀(Occam's razor)原理:在所有可能选择的模型中,能够**很好地解释已知数据**并且**十分简单**才是最好的模型,也就是应该选择的模型。

从贝叶斯估计的角度来看,**正则化项**对应于模型的**先验概率**。可以假设复杂的模型有较小的先验概率,简的模型有较大的先验概率。

1.3.2 交叉验证

e

1.4 泛化能力

f

1.4.1 泛化误差

g

1.4.2 泛化误差上界

a

1.5 生成模型与判别模型

a

1.6 分类问题

a

1.7 标注问题

c

1.8 回归问题

b

一个常问的问题: 平方损失在做分类问题的损失函数时, 有什么缺陷?

一方面,直观上看,平方损失函数**对每一个输出结果都十分看重**,而交叉熵**只看重正确分类**的结果。例如三分类问题,如果预测的是 (a,b,c),而实际结果是 (1,0,0),那么:

$$mse = (a-1)^2 + b^2 + c^2$$

$$crossentropy = -1 \times \log a - 0 \times \log b - 0 \times \log c = -\log a$$

所以,交叉熵损失的梯度只和正确分类有关。而平方损失的梯度和错误分类有关,**除了让正确分类尽可能变大,还会让错误分类都变得更平均**。实际中后面这个调整在分类问题中是不必要的,而回归问题上这就很重要。

另一方面,从理论角度分析。两个损失的源头不同。平方损失函数**假设最终结果都服从高斯分布**,而高斯分布的随机变量实际是一个**连续变**量,而非离散变量。如果假设结果变量服从均值 t,方差 σ 的高斯分布,那么利用最大似然法可以优化其负对数似然,最终公式变为:

$$\max \sum_{i}^{N} \left[-\frac{1}{2} \log(2\pi\sigma^2) - \frac{(t_i - y)^2}{2\sigma^2} \right]$$

除去与y无关的项,剩下的就是平方损失函数。

2 感知机

d

3 k 近邻法

e

4 朴素贝叶斯法

参考https://www.cnblogs.com/jiangxinyang/p/9378535.html

4.1 贝叶斯公式

$$p(\theta|X) = \frac{p(X|\theta)p(\theta)}{p(X)}$$

又可以写为:

$$posterior = \frac{likelihood*prior}{evidence}$$

其中:

• posterior: 通过样本 X 得到参数 θ 的概率,即后验概率

• likelihood: 通过参数 θ 得到样本 X 的概率,即似然函数。

• prior: 参数 θ 的先验概率

• evidence: $p(X) = \int p(X|\theta)p(\theta)d\theta$ 。 样本 X 发生的概率,是各种 θ 条件下发生的概率的积分。

4.2 极大似然估计 (MLE)

极大似然估计的核心思想是:认为**当前发生的事件是概率最大的事件。**因此就可以给定的数据集,使得该数据集**发生的概率最大**来求得模型中的参数。

似然函数如下:

$$p(X|\theta) = \prod_{i=1}^{n} p(x_i|\theta)$$

为便于计算,对似然函数两边取对数,得到对数似然函数:

$$LL(\theta) = \log p(X|\theta)$$

$$= \log \prod_{i=1}^{n} p(x_i|\theta)$$

$$= \sum_{i=1}^{n} \log p(x_i|\theta)$$

极大似然估计**只关注当前的样本**,也就是只关注当前发生的事情,**不考虑事情的先验情况**。由于计算简单,而且不需要关注先验知识,因此在 机器学习中的应用非常广,最常见的就是**逻辑回归**。

4.3 最大后验估计 (MAP)

最大后验估计中引入了**先验概率**(先验分布属于**贝叶斯学派**引入的,像 L1,L2 正则化就是对参数引入了**拉普拉斯先验**分布和**高斯先验**分布),而且最大后验估计要求的是 $p(\theta|X)$

$$\begin{split} f(x) &= \arg\max_{\theta} p(\theta|X) \\ &= \arg\max_{\theta} \frac{p(X|\theta)p(\theta)}{p(X)} \\ &= \arg\max_{\theta} p(X|\theta)p(\theta) \end{split}$$

其中因为分母 p(X) 与 heta 无关,所以可以去掉,同样地,取 \log :

$$f(x) = \arg \max_{\theta} \log p(X|\theta)p(\theta)$$
$$= \arg \max_{\theta} \{ \sum_{i=1}^{n} \log p(x_i|\theta) + \log p(\theta) \}$$

最大后验估计不只是关注当前的样本的情况,还关注已经发生过的先验知识。

最大后验估计和最大似然估计的区别:

最大后验估计允许我们**把先验知识加入到估计模型中**,这在**样本很少的时候是很有用的**(因此朴素贝叶斯在较少的样本下就能有很好的表现),因为**样本很少**的时候我们的**观测结果很可能出现偏差**,此时先验知识会把估计的结果"拉"向先验,实际的预估结果将会在先验结果的两侧形成一个顶峰。通过调节先验分布的参数,比如 beta 分布的 α , β ,我们还可以调节把估计的结果"拉"向先验的幅度, α , β 越大,这个顶峰越尖锐。这样的参数,我们叫做预估模型的"超参数"。

4.4 贝叶斯估计

贝叶斯估计和极大后验估计有点相似,都是以最大化后验概率为目的。区别在于:

- 极大似然估计和极大后验估计都是只返回了的预估值。
- 极大后验估计在计算后验概率的时候,把**分母** p(X) 忽略了,在进行**贝叶斯估计的时候则不能忽略**
- 贝叶斯估计要计算整个后验概率的概率分布

5 决策树

W

6 logistic 回归与最大熵模型

o

7 支持向量机

u

8 提升方法

8.1 gbdt

参考https://www.cnblogs.com/pinard/p/6140514.html

梯度提升树 (Gradient Boosting Decison Tree, 以下简称 GBDT) 有很多简称,有 GBT (Gradient Boosting Tree) , GTB (Gradient Tree Boosting), GBRT (Gradient Boosting Regression Tree) , MART(Multiple Additive Regression Tree) 等等。

8.1.1 gbdt 概述

在 Adaboost 中, 我们是利用前一轮迭代弱学习器的误差率来更新训练集的权重,这样一轮轮的迭代下去。

 GBDT 也是迭代,但是弱学习器限定了只能使用 CART 回归树模型,同时迭代思路和 $\mathsf{Adaboost}$ 也有所不同。

假设我们前一轮迭代得到的强学习器是 $f_{t-1}(x)$,损失函数是 $L(y,f_{t-1}(x))$,本轮迭代的目标是找到一个 CART 回归树模型的弱学习器 $h_t(x)$,使得本轮的损失函数 $L(y,f_t(x))=L(y,f_{t-1}(x)+h_t(x))$ 最小。也就是说,要找到一个决策树,使得样本的损失 $L(y-f_{t-1}(x),h_t(x))$ 最小。

8.1.2 gbdt 的负梯度拟合

第 t 轮的第 i 个样本的损失函数的负梯度:

$$r_{ti} = -\left[\frac{\partial L(y_i, f(x_i)))}{\partial f(x_i)}\right]_{f(x) = f_{t-1}(x)}$$

利用

9 EM 算法及其推广

e

10 隐马尔可夫模型

c

11 条件随机场

b

12 附录

e

12.1 矩阵

e

12.2 优化

c

12.2.1 拉格朗日乘子法

拉格朗日乘子法 (Lagrange multipliers) 是一种寻找多元函数在**一组约束下**的极值的方法。通过引入拉格朗日乘子,将 d 个变量和 k 个约束条件的最优化问题转化为具有 d+k 个变量的无约束优化问题求解。

12.2.1.1 等式约束

假设 x 是 d 维向量,要寻找 x 的某个取值 x^* ,使目标函数 f(x) 最小且同时满足 g(x)=0 的约束。

从几何角度看,目标是在由方程 g(x)=0 确定的 d-1 维曲面上,寻找能使目标函数 f(x) 最小化的点。

- 1. 对于约束曲面 g(x)=0 上的**任意点**x,该点的梯度 $\nabla g(x)$ 正交于约束曲面
- 2. 在最优点 x^* ,目标函数 f(x) 在该点的梯度 $\nabla f(x^*)$ 正交于约束曲面

对于第1条,梯度本身就与曲面的切向量垂直,是曲面的法向量,并且指向数值更高的等值线。

证明:

参考http://xuxzmail.blog.163.com/blog/static/251319162010328103227654/

z = f(x, y) 的等值线: $\Gamma : f(x, y) = c$, 两边求微分:

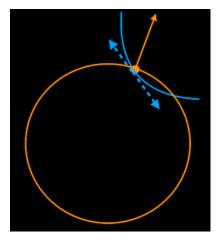
$$df(x,y) = dc$$
$$\frac{\partial f}{\partial x}dx + \frac{\partial f}{\partial y}dy = 0$$

看成两个向量的内积:

$$\frac{\partial f}{\partial x}dx + \frac{\partial f}{\partial y}dy = \left\{\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}\right\} \cdot \left\{dx, dy\right\} = 0$$

而内积 $a\cdot b=|a||b|cos\theta$ 为 0 说明夹角是 90 度,而 $\left\{\frac{\partial f}{\partial x},\frac{\partial f}{\partial y}\right\}$ 是梯度向量, $\left\{dx,dy\right\}$ 是等值线的切向量,所以梯度向量和切向量是垂直的。

对于**第 2** 条,可以用反证法,如下图,蓝色是 g(x)=0,橙色是 f(x) 的等值线 (图里假设 $f(x)=x^2+y^2$),交点的 $\nabla f(x^*)$ 的梯度和 g(x) 的切面不垂直,那么,可以找到更小的等值线,使夹角更接近 90 度,也就是说,这个点不是真正的最优点 x^* 。



所以,在最优点 x^* 处,梯度 $\nabla g(x)$ 和 $\nabla f(x)$ 的方向必然相同或相反,也就是存在 $\lambda \neq 0$,使得:

$$\nabla f(x^*) + \lambda \nabla g(x^*) = 0$$

 λ 是拉格朗日乘子,定义拉格朗日函数

$$L(x,\lambda) = f(x) + \lambda g(x)$$

 $L(x,\lambda)$ 对 x 的偏导 $\nabla_x L(x,\lambda)$ 置 0, 就得到:

$$\nabla f(x) + \lambda \nabla g(x) = 0$$

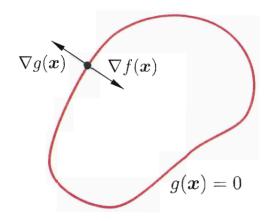
而 $L(x,\lambda)$ 对 λ 的偏导 $\nabla_{\lambda}L(x,\lambda)$ 置 0, 就得到

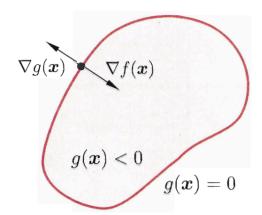
$$g(x) = 0$$

所以,原约束问题可以转化为对 $L(x,\lambda)$ 的无约束优化问题。

12.2.1.2 不等式约束

考虑不等式约束 q(x) < 0,最优点或者在边界 q(x) = 0 上,或者在区域 q(x) < 0 中。





• 对于 g(x) < 0

相当于使 f(x) 取得最小值的点落在可行域内,所以**约束条件相当于没有用**,所以,直接对 f(x) 求极小值即可。因为 $L(x,\lambda)=f(x)+\lambda g(x)$,所以

$$\nabla_x L(x,\lambda) = \nabla f(x) + \lambda \nabla g(x)$$

因为 g(x) < 0,想要只让 $\nabla f(x) = 0$,那么令 $\lambda = 0$ 即可。

• 对于 q(x) = 0

这就变成了等式约束,且此时 $\nabla f(x^*)$ 和 $\nabla g(x^*)$ 反向相反。因为在 g(x)=0 越往里值是越小的,而梯度是指向等值线高的方向,所以梯度是指向外的。而 f(x) 的可行域又在 g(x) 的里面和边界上,我们要找的是 f(x) 的最小值,所以 f(x) 的梯度是指向内部的。

而 $\nabla f(x) + \lambda \nabla g(x) = 0$, 两个又是反向的, 所以 $\lambda > 0$ 。

结合 $g(x) \leq 0$ 和 g(x) = 0 两种情况的结论,就得到了 KKT(Karush-Kuhn-Tucker)条件

其中 $\lambda g(x)=0$ 是因为 λ 和 g(x) 至少一个是 $oldsymbol{0}$,而且不能都不是 $oldsymbol{0}$ 。

以上三个条件有各自的名字:

- Primal feasibility(原始可行性): $g(x) \leq 0$
- Dual feasibility(对偶可行性): $\lambda \geq 0$
- Complementary slackness: $\lambda g(x) = 0$

12.2.1.3 带等式和不等式约束的拉格朗日乘子法

对于多个约束的情形,m 个等式约束和 n 个不等式约束,可行域 $\mathbb{D}\subset\mathbb{R}^d$ 非空的优化问题:

$$\min_{x} f(x)$$
s.t $h_i(x) = 0, i = 1, ..., m$
 $g_j(x) \le 0, j = 1, ..., n$

引入拉格朗日乘子 $\lambda=(\lambda_1,\lambda_2,...,\lambda_m)^T$ 和 $\mu=(\mu_1,\mu_2,...,\mu_n)^T$,相应的拉格朗日函数为:

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^{m} \lambda_i h_i(x) + \sum_{j=1}^{n} \mu_j g_j(x)$$

由不等式约束引入的 KKT 条件 (j=1,2,...n) 为

$$\begin{cases} g_j(x) \le 0\\ \mu_j \ge 0\\ \mu_j g_j(x) = 0 \end{cases}$$

12.2.2 梯度下降

12.2.2.1 《统计学习方法》的视角

假设 f(x) 有一阶连续偏导,对于无约束的最优化问题而言:

$$\min_{x \in R^n} f(x)$$

f(x) 在 $x^{(k)}$ 附近的一阶泰勒展开如下,其中 $g_k=g(x^{(k)})=\nabla f(x^{(k)})$ 是 f(x) 在 $x^{(k)}$ 的梯度:

$$f(x) = f(x^{(k)}) + g_k^T(x - x^{(k)})$$

所以对于 $x = x^{(k+1)}$:

$$f(x^{(k+1)}) = f(x^{(k)}) + g_k^T(x^{(k+1)} - x^{(k)})$$

令 $x^{(k+1)}=x^{(k)}+\lambda_k p_k$, p_k 是搜索方向, λ_k 是步长,代入上式,有

$$f(x^{(k+1)}) = f(x^{(k)}) + g_k^T (x^{(k)} + \lambda_k p_k - x^{(k)})$$

= $f(x^{(k)}) + g_k^T \lambda_k p_k$

为了让每次迭代的函数值变小,可以取 $p_k = -\nabla f(x^{(k)})$

把 λ_k 看成是可变化的,所以需要搜索 λ_k 使得

$$f(x^{(k)} + \lambda_k p_k) = \min_{\lambda > 0} f(x^{(k)} + \lambda p_k)$$

梯度下降法:

输入: 目标函数 f(x), 梯度 $g(x) = \nabla f(x)$, 精度要求 ε 。

输出: f(x) 的极小点 x^* 。

- 1. 取初始值 $x^{(0)} \in \mathbb{R}^n$,置 k = 0
- 2. 计算 $f(x^{(k)})$
- 3. 计算梯度 $g_k=g(x^{(k)})$,当 $\|g_k\|<arepsilon$,则停止计算,得到近似解 $x^*=x^{(k)}$;否则,令 $p_k=-g(x^{(k)})$,求 λ_k 使得

$$f(x^{(k)} + \lambda_k p_k) = \min_{\lambda > 0} f(x^{(k)} + \lambda p_k)$$

- 4. 置 $x^{(k+1)} = x^{(k)} + \lambda_k p_k$,计算 $f(x^{(k+1)})$ 当 $\left\| f(x^{(k+1)}) f(x^{(k)}) \right\| < \varepsilon$ 或 $\left\| x^{(k+1)} x^{(k)} \right\| < \varepsilon$ 时,停止迭代,令 $x^* = x^{(k+1)}$
- 5. 否则, 置 k = k + 1, 转第 3 步

只有当目标函数是**凸函数**时,梯度下降得到的才是**全局最优解**。

12.2.2.2 《机器学习》的视角

梯度下降是一阶 (first order)(只用一阶导,不用高阶导数)优化方法,是求解无约束优化问题最简单、最经典的方法之一。 考虑无约束优化问题 $\min_x f(x)$,f(x) 是连续可微函数,如果能构造一个序列 x^0, x^1, x^2, \ldots 满足

$$f(x^{t+1}) < f(x^t), t = 0, 1, 2, \dots$$

那么不断执行这个过程,就可以收敛到局部极小点,根据泰勒展开有:

$$f(x) = f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)})$$

$$f(x + \Delta x) = f(x^{(k)}) + \nabla f(x^{(k)})^T (x + \Delta x - x^{(k)})$$

$$= f(x^{(k)}) + \nabla f(x^{(k)})^T (x - x^{(k)}) + \nabla f(x^{(k)})^T \Delta x$$

$$= f(x) + \nabla f(x^{(k)})^T \Delta x$$

而 $\nabla f(x^{(k)})^T \Delta x$ 是一个标量, 其转置等于自己, 所以

$$f(x + \Delta x) = f(x) + \Delta x^T \nabla f(x^{(k)})$$

想要让 $f(x + \Delta x) < f(x)$, 只需要令:

$$\Delta x = -\gamma \nabla f(x)$$

其中的步长 γ 是一个小常数

如果 f(x) 满足 L-Lipschitz 条件,也就是说对于任意的 x,存在常数 L,使得 $\|\nabla f(x)\| \le L$ 成立,那么设置步长为 $\frac{1}{2L}$ 就可以确保收敛到局部极小点。

同样地,当目标函数是凸函数时,局部极小点就对应全局最小点,此时梯度下降可以确保收敛到全局最优解。

12.2.3 牛顿法

12.2.3.1 二阶导基本性质

对于点 $x = x_0$,

- 一阶导 $f'(x_0)=0$ 时,如果二阶导 $f''(x_0)>0$,那么 $f(x_0)$ 是极小值, x_0 是极小点
- 一阶导 $f'(x_0)=0$,如果二阶导 $f''(x_0)<0$,那么 $f(x_0)$ 是极大值, x_0 是极大点
- 一阶导 $f'(x_0) = 0$, 如果二阶导 $f''(x_0) = 0$, 那么 x_0 是鞍点

证明:

对于任意 x_1 ,根据二阶泰勒展开,有

$$f(x_1) = f(x_0) + f'(x_0)(x_1 - x_0) + \frac{1}{2}f''(x_0)(x_1 - x_0)^2 + \dots + R_n(x_1)$$

因为 $f''(x_0) > 0$ 且 $f'(x_0) = 0$,所以,不论 $x_1 > x_0$ 还是 $x_1 < x_0$,总有 $f(x_1) > f(x_0)$,也就是周围的函数值都比 $f(x_0)$ 大,而 x_0 又是极值点,所以是极小点。

12.2.3.2 牛顿法

对于矩阵形式,x 是一个 nx1 的列向量,H(x) 是 f(x) 的海赛矩阵,即二阶导,shape 是 $n\times n$:

$$f(x) = f(x^{(x)}) + g_k^T(x - x^{(k)}) + \frac{1}{2}(x - x^{(k)})^T H(x^{(k)})(x - x^{(k)})$$

函数 f(x) 有极值的必要条件是在极值点处一阶导为 0,特别地,当 $H(x^{(k)})$ 是正定矩阵时(二阶导大于 0),是极小值。

牛顿法利用极小点的必要条件 $\nabla f(x)=0$,每次迭代从点 $x^{(k)}$ 开始,求目标函数极小点,作为第 k+1 次迭代值 $x^{(k+1)}$,具体地,假设 $\nabla f(x^{(k+1)})=0$,有

$$f(x) = f(x^{(x)}) + g_k^T(x - x^{(k)}) + \frac{1}{2}(x - x^{(k)})^T H(x^{(k)})(x - x^{(k)})$$

$$= f(x^{(x)}) + [g_k^T + \frac{1}{2}(x - x^{(k)})^T H(x^{(k)})](x - x^{(k)})$$

$$= f(x^{(x)}) + [g_k + \frac{1}{2}H(x^{(k)})(x - x^{(k)})]^T (x - x^{(k)})$$

把其中的 $g_k+\frac{1}{2}H(x^{(k)})(x-x^{(k)})$ 看成一阶导,则上式就是一阶泰勒展开。记 $H^k=H(x^{(k)})$,令 $x=x^{(k+1)}$,令一阶导为 0:

$$g_k + \frac{1}{2}H^k(x^{(k+1)} - x^{(k)}) = 0$$

$$g_k = -\frac{1}{2}H^k(x^{(k+1)} - x^{(k)})$$

$$-2H_k^{-1}g_k = x^{(k+1)} - x^{(k)}$$

$$x^{(k+1)} = -2H_k^{-1}g_k + x^{(k)}$$

可以无视这个 2, 变成:

$$x^{(k+1)} = x^{(k)} - H_k^{-1} g_k$$

或者

$$x^{(k+1)} = x^{(k)} + p_k$$

其中,

$$H_k p_k = -g_k$$

牛顿法:

输入: 目标函数 f(x),梯度 $g(x) = \nabla f(x)$,海赛矩阵 H(x),精度要求 ε 。

输出: f(x) 的极小点 x^* 。

1. 取初始点 $x^{(0)}$, 置 k=0

- 2. 计算 $g_k = g(x^{(k)})$
- 3. 若 $\|g_k\| < arepsilon$,则停止计算,得到近似解 $x^* = x^{(k)}$
- 4. 计算 $H_k = H(x^{(k)})$, 并求 p_k , 满足

$$H_k p_k = -g_k$$

- 5. $\mathbb{E} x^{(k+1)} = x^{(k)} + p_k$
- 6. 置 k = k + 1, 转到第 2 步

其中的步骤 4,求 p_k 时, $p_k=-H_k^{-1}g_k$ 需要求解 H_k^{-1} 很复杂。

12.2.4 拟牛顿法的思路

基本想法就是通过一个 n 阶矩阵 $G_k = G(x^{(k)})$ 来近似代替 $H^{-1}(x^{(k)})$ 。

12.2.5 DFP(Davidon-Fletcher-Powell)

X

12.2.6 BFGS(Broydon-Fletcher-Goldfarb-Shanno)

X

12.3 拉格朗日对偶性

 \mathbf{X}

12.4 信息论相关

12.4.1 凸集

假设 S 为在实或复向量空间的集。若对于所有 $x,y\in S$ 和所有的 $t\in [0,1]$ 都有 $tx+(1-t)y\in S$,则 S 称为凸集。也就是说,S 中任意两点间的线段都属于 S

性质:

如果 S 是凸集,对于任意的 $u_1,u_2,...,u_r\in S$,以及所有的非负 $\lambda_1,\lambda_2,...,\lambda_r$ 满足 $\lambda_1+\lambda_2+...+\lambda_r=1$,都有 $\sum_{k=1}^r\lambda_ku_k\in S$ 。这个组合称为 $u_1,u_2,...,u_r$ 的凸组合。

12.4.2 凸函数

函数是凸函数:曲线上任意两点 x 和 y 所作割线(与函数图像有两个不同交点的直线,如果只有一个交点,那就是切线)一定在这两点间的函数图象的上方:

$$tf(x) + (1-t)f(y) \ge f(tx + (1-t)y), 0 \le t \le 1$$

有如下几个常用性质:

- 一元可微函数在某个区间上是凸的,当且仅当它的导数在该区间上单调不减。
- 一元连续可微函数在区间上是凸的,当且仅当函数位于**所有它的切线的上方**:对于区间内的所有 x 和 y,都有 f(y)f(x) + f'(x)(yx)(右边就是一阶泰勒展开)。特别地,如果 f'(c)=0,那么 f(c) 是 f(x) 的最小值。

- 一元二阶可微的函数在区间上是凸的,当且仅当它的二阶导数是非负的;这可以用来判断某个函数是不是凸函数。如果它的二阶导数是正数,那么函数就是严格凸的,但反过来不成立。
- 多元二次可微的连续函数在凸集上是凸的,当且仅当它的黑塞矩阵在凸集的内部是半正定的

12.4.3 KL 散度

熵的小结: https://blog.csdn.net/haolexiao/article/details/70142571

相对熵 (relative entropy) 又称为 **KL** 散度 (Kullback–Leibler divergence, 简称 KLD), 信息散度 (**information divergence**), 信息增益 (**information gain**)。

KL 散度是两个概率分布 P 和 Q 差别的非对称性的度量。KL 散度是用来度量使用基于 Q 的编码来编码来自 P 的样本 平均所需的额外的 位元数。典型情况下,P 表示数据的真实分布,Q 表示数据的理论分布,模型分布,或 P 的近似分布。

注意: $D_{KL}(P||Q)$ 是指的用分布 ${f Q}$ 来近似数据的真实分布 ${f P}$,先写 ${f P}$ 再写 ${f Q}$,公式里没有- ${f ln}$ 的时候,就是 ${f p}/{f q}$ 对于离散随机变量:

$$D_{KL}(P||Q) = \sum_{i} P(i) ln \frac{P(i)}{Q(i)} = -\sum_{i} P(i) ln \frac{Q(i)}{P(i)}$$

KL 散度仅当概率 ${f P}$ 和 ${f Q}$ 各自总和均为 ${f 1}$,且对于任何 ${f i}$ 皆满足 Q(i)>0 及 P(i)>0 时,才有定义。如果出现 0ln0,当做 0 对于连续随机变量:

$$D_{KL}(P||Q) = \int_{-\infty}^{\infty} p(x) ln \frac{p(x)}{q(x)} dx$$

性质:

KL 散度大于等于 0

证明:

先了解一下 Jensen 不等式:

如果 φ 是一个凸函数,那么有:

$$\varphi(E(x)) < E(\varphi(x))$$

对于**离散随机变量**, $\sum_{i=1}^{n} \lambda_i = 1$:

$$\varphi(\sum_{i=1}^{n} g(x_i)\lambda_i) \le \sum_{i=1}^{n} \varphi(g(x_i))\lambda_i$$

当我们取 g(x)=x, $\lambda_i=1/n$, $\varphi(x)=log(x)$ 时, 就有

$$log(\sum_{i=1}^{n} \frac{x_i}{n}) \ge \sum_{i=1}^{n} \frac{log(x_i)}{n}$$

对于**连续随机变**量,如果 f(x) 是非负函数,且满足(f(x) 是概率密度函数):

$$\int_{-\infty}^{\infty} f(x)dx = 1$$

如果 φ 在 g(x) 的值域中是凸函数,那么

$$\varphi(\int_{-\infty}^{\infty} g(x)f(x)dx) \le \int_{-\infty}^{\infty} \varphi(g(x))f(x)dx$$

特别地, 当 g(x) = x 时, 有

$$\varphi(\int_{-\infty}^{\infty} x f(x) dx) \le \int_{-\infty}^{\infty} \varphi(x) f(x) dx$$

回到这个问题中, $g(x)=rac{q(x)}{p(x)},\; \varphi(x)=-logx$ 是一个严格凸函数,那么 $\varphi(g(x))=-lograc{q(x)}{p(x)},\;$ 所以

$$D_{KL}(P||Q) = \int_{-\infty}^{\infty} p(x) ln \frac{p(x)}{q(x)} dx$$

$$= \int_{-\infty}^{\infty} p(x) (-ln \frac{q(x)}{p(x)}) dx$$

$$= \int_{-\infty}^{\infty} (-ln \frac{q(x)}{p(x)}) p(x) dx$$

$$\geq -ln (\int_{-\infty}^{\infty} \frac{q(x)}{p(x)} p(x) dx)$$

$$\geq -ln (\int_{-\infty}^{\infty} q(x) dx)$$

$$= -ln 1 = 0$$

12.5 采样

假设有一个很复杂的概率密度函数 p(x),求解随机变量基于此概率下的某个函数期望,即:

$$E_{x \sim p(x)}[f(x)]$$

求解有两种方法:

解析法:

将上式展开成积分,并通过积分求解:

$$\int_{x} p(x)f(x)dx$$

对于简单的分布,可以直接这么做。但 dnn 就不可行了。

蒙特卡洛法

根据大数定理, 当采样数量足够大时, 采样的样本就可以无限近似地表示原分布:

$$\frac{1}{N} \sum_{x_i \sim p(x), i=1}^{N} f(x_i)$$

12.5.1 拒绝采样

拒绝采样又叫接受/拒绝采样 (Accept-Reject Sampling),对于目标分布 p(x),选取一个容易采样的参考分布 q(x),使得对于任意 x 都有 $p(x) \leq M \cdot q(x)$,则可以按如下过程采样:

- 从参考分布 q(x) 中随机抽取一个样本 x_i
- ・ 从均匀分布 U(0,1) 产生一个随机数 u_i ・ 如果 $u_i \leq \frac{p(x_i)}{Mq(x_i)}$,则接受样本 x_i ,否则拒绝。

重新进行如上 3 个步骤,直到新产生的样本 x_i 被接受

其中的第三步是因为 $p(x) \leq M \cdot q(x)$,所以 $\frac{p(x_i)}{Mq(x_i)} \leq 1$,说明只有函数值在 $p(x_i)$ 下方的 x_i 才接受,所以 $x_i \sim p(x)$ 。相当于为目标 分布 p(x) 选一个包络函数 $M\cdot q(x)$,包络函数紧,每次采样时样本被接受的概率越大,采样效率越高。实际应用中还有自适应拒绝采样等。

12.5.2 重要性采样

强化学习经常使用重要性采样。重要性采样主要应用在一些难以直接采样的数据分布上。

我们令待采样分布为 p(x), 有另一个简单可采样且定义域和 p(x) 相同的概率密度函数为 $\tilde{p}(x)$, 可以得到:

$$\begin{split} E_{x \sim p(x)}[f(x)] &= \int_x p(x) f(x) dx \\ &= \int_x \tilde{p}(x) \frac{p(x)}{\tilde{p}(x)} f(x) dx \\ &= E_{x \sim \tilde{p}(x)} [\frac{p(x)}{\tilde{p}(x)} f(x)] \\ &\simeq \frac{1}{N} \sum_{x \in \tilde{p}(x)}^N \sum_{i=1}^N \frac{p(x)}{\tilde{p}(x)} f(x) \end{split}$$

因此,只需要从简单分布 $\tilde{p}(x)$ 中采样,然后分别计算 p(x)、 $\tilde{p}(x)$ 和 f(x) 就可以了。

最好选择一个和原始分布尽量接近的近似分布进行采样。

例如,要对一个均值 1,方差 1 的正态分布进行采样,有两个可选的分布:均值 1 方差 0.5 和均值 1 方差 2。

从图像上可以看到方差为 0.5 的过分集中在均值附近,而且方差为 2 的与原分布重合度较高,所以应该选方差为 2 的。

12.5.3 马尔可夫蒙特卡洛采样 (MCMC)

如果是高维空间的随机向量,拒绝采样和重要性采样经常难以找到合适的参考分布,采样效率低下(样本的接受概率低或者重要性权重低),此时可 以考虑马尔可夫蒙特卡洛采样法。

蒙特卡洛法指基于采样的数值近似求解方法,马尔可夫链用于进行采样。

基本思想是:

- 针对待采样的目标分布,构造一个马尔可夫链,使得该马尔可夫链的平稳分布就是目标分布;
- 然后从任何一个初始状态出发,沿着马尔可夫链进行状态转移,最终得到的状态转移序列会收敛到目标分布
- 由此可以得到目标分布的一系列样本

核心点是如何构造合适的马尔可夫链,即确定马尔可夫链的状态转移概率。

12.5.3.1 Metropolis-Hastings 采样

对于目标分布 p(x), 首先选择一个容易采样的参考条件分布 $q(x^*|x)$, 并令

$$A(x, x^*) = \min\{1, \frac{p(x^*)q(x|x^*)}{p(x)q(x^*|x)}\}\$$

然后根据如下过程采样:

- 随机选一个初始样本 $x^{(0)}$
- For t = 1, 2, 3, ...:
 - 根据参考条件分布 $q(x^*|x^{(t-1)})$ 抽取一个样本 x^* ;
 - 根据均匀分布 U(0,1) 产生随机数 u;
 - 若 $u < A(x^{(t-1)}, x^*)$,则令 $x^{(t)} = x^*$ 【接受新样本】,否则令 $x^{(t)} = x^{(t-1)}$ 【拒绝新样本,维持旧样本】

可以证明,上述过程得到的样本序列 $\{...,x^{(t-1)},x^{(t)},...\}$ 最终会收敛到目标分布p(x)

12.5.3.2 吉布斯采样

吉布斯采样是 **Metropolis-Hastings 算法的一个特例**,核心思想是**只对样本的一个维度**进行采样和更新。对于目标分布 p(x),其中 $x=(x_1,x_2,...,x_d)$ 是一个多维向量,按如下过程采样:

- 随机选择初始状态 $x^{(0)} = (x_1^{(0)}, x_2^{(0)}, ..., x_d^{(0)})$
- For t = 1, 2, 3, ...

 - 形成新的样本 $x^{(t)} = (x_1^{(t)}, x_2^{(t)}, ..., x_d^{(t)})$

同样可以证明,上述过程得到的样本序列 $\{...,x^{(t-1)},x^{(t)},...\}$ 会收敛到目标分布p(x)。另外,步骤2中对样本每个维度的抽样和更新操作,不是必须按下标顺序进行的,可以是随机顺序。

注意点:

- 拒绝采样中,如果某一步中采样被拒绝,则**该步不会产生新样本,需要重新采样**。但 **MCMC** 采样**每一步都会产生一个样本**,只是有时候这个样本与之前的样本一样而已。
- MCMC 采样是在**不断迭代**过程中**逐渐收敛**到平稳分布的。实际应用中一般会对得到的样本序列进行"burn-in"处理,即截除掉序列中最开始的一部分样本,**只保留后面的样本**。

MCMC 得到的样本序列中相邻的样本是**不独立的**,因为后一个样本是由前一个样本根据特定的转移概率得到的。如果仅仅是采样,并不要求样本之间相互独立。

如果确实需要产生独立同分布的样本,可以:

- 同行运行多条马尔可夫链,这样不同链上的样本是独立的
- 或者在同一条马尔可夫链上每隔若干个样本才选取一个,这样选出来的样本也是近似独立的。