Contents

1 概述

1.1 统计学习三要素

1.1.1 模型

监督学习中，模型是要学习的条件概率分布或决策函数。

1.1.1.1 模型的假设空间

假设空间是所有可能的条件概率分布或决策函数

1.1.1.1.1 定义 1

可以定义为决策函数的集合：

$$\mathcal{F} = \{f|Y = f(X)\}$$

- X 和 Y 是定义在 $\mathcal{X}$ 和 $\mathcal{Y}$ 上的变量
- $\mathcal{F}$ 是一个参数向量决定的函数族：

$$\mathcal{F} = \{f|Y = f_\theta(X), \theta \in R^n\}$$

参数向量 θ 取值于 n 维欧式空间 R^n，称为参数空间

1.1.1.1.2 定义 2

也可以定义为条件概率的集合：

$$\mathcal{F} = \{P|P(Y|X)\}$$

- X 和 Y 是定义在 $\mathcal{X}$ 和 $\mathcal{Y}$ 上的随机变量
- $\mathcal{F}$ 是一个参数向量决定的条件概率分布族：

$$\mathcal{F} = \{P|P_\theta(Y|X), \theta \in R^n\}$$

1.1.2 策略

1.1.2.1 损失函数与风险函数

损失函数（**loss function**）或代价函数（**cost function**）：度量预测值 $f(X)$ 与真实值 Y 的误差程度，记为 $L(Y, f(X))$，是个非负实值函数。损失函数越小，模型越好。

- 0-1 损失函数：

$$L(Y, f(X)) = \begin{cases} 0 & Y \neq f(X) \\ 1 & Y = f(X) \end{cases}$$

- 平方损失函数：

$$L(Y, f(X)) = (Y - f(X))^2$$

- 绝对损失函数：

$$L(Y, f(x)) = |Y - f(X)|$$

- 对数损失函数 (logarithmic loss function)/对数似然损失函数 (log-likelihood loss function)：

$$L(Y, P(Y|X)) = -logP(Y|X)$$

风险函数 **(risk function)** 或期望损失 **(expected loss)**：X 和 Y 服从联合分布 $P(X, Y)$，理论上模型 $f(X)$ 关于联合分布$P(X, Y)$ 的平均意义下的损失：

$$R_{exp}(f) = E_P[L(Y, f(X))] = \int_{\mathcal{X}\times\mathcal{Y}} L(y, f(x))P(x, y)dxdy$$

学习的目标：选择期望风险最小的模型。但联合分布 $P(X, Y)$ 是未知的，所以无法直接计算 $R_{exp}(f)$。所以监督学习是病态问题（ill-formed problem）：一方面需要联合分布，另一方面联合分布是未知的。

给定训练集：

$$T = \{(x_1, y_1), ...(x_N, y_N)\}$$

经验风险 **(expirical risk)**/经验损失 **(expirical loss)**：模型 $f(X)$ 关于训练集的平均损失

$$R_{emp}(f) = \frac{1}{N}\sum_{i=1}^{N} L(y_i, f(x_i))$$

根据大数定律，当样本容量 N 趋向无穷时，经验风险 R_{emp} 趋于期望风险 $R_{exp}(f)$。

1.1.2.2 经验风险最小化与结构风险最小化

经验风险最小化（**empirical risk minimization, ERM**）：经验风险最小的模型就是最优模型。所以需要求解的最优化问题是：

$$min_{f\in\mathcal{F}} R_{erm} = min_{f\in\mathcal{F}} \frac{1}{N} L(y_i, f(x_i))$$

当满足以下两个条件时，经验风险最小化就等价于极大似然估计（maximum likelihood estimation）：

- 模型是条件概率分布

- 损失函数是对数损失函数

当样本量足够大时，ERM 能有很好的效果，但样本量不够多时，为了防止过拟合，需要用下面的方法。

结构风险最小化（**structual risk minimization, SRM**）：结构风险 = 经验风险 + 表示模型复杂度的正则化项 (regularizer) 或罚项 (penalty term)。结构风险定义如下：

$$R_{srm}(f) = \frac{1}{N}\sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

$J(f)$ 是模型的复杂度，模型越复杂，$J(f)$ 越大。$\lambda \geq 0$ 是用于权衡经验风险和模型复杂度的系数。

当满足以下 3 个条件时，结构化风险最小化等价于）贝叶斯估计中的最大后验概率估计 (maximum posterior probability estimation, MAP) :

- 模型是条件概率分布
- 损失函数是对数损失函数
- 模型复杂度由模型的先验概率表示

所以结构风险最小化就是求解优化问题：

$$min_{f\in\mathcal{F}} \frac{1}{N}\sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

1.1.3 算法

算法指的是学习模型的具体方法，即使用什么计算方法求解最优模型。

因为统计学习问题归结为最优化问题，所以统计学习的算法就是求解最优化问题的算法。

- 如果有显式的解析解，此最优化问题就比较简单
- 如果没有，需要用数值计算方法求解，需要考虑如何保证找到全局最优解，并使求解过程高效

1.2 模型评估与模型选择

1.2.1 训练误差与测试误差