# Contents

	既述
	1.1 统计学习三要素
	1.1.1 模型
	1.1.2 策略
	1.1.3 算法
	1.2 模型评估与模型选择
	1.2.1 训练误差与测试误差
	1.2.2 过拟合与模型选择
	1.3 正则化与交叉验证
	1.3.1 正则化
	1.3.2   交叉验证
	$1.4$ 泛化能力 $\dots$
	1.4.1 泛化误差
	1.4.2 泛化误差上界
	$1.5$ 生成模型与判别模型 $\dots\dots\dots\dots\dots\dots$
	1.6 分类问题
	1.7 标注问题
	$1.8$ 回归问题 $\dots\dots\dots\dots\dots\dots$
	=i^xn+n
	<del></del> <del></del>
	k 近邻法
	朴素贝叶斯法
	+ ***
	夬策树
	logistic 回归与最大熵模型
	ogistic Eta Japanija Eta Eta Eta Eta Eta Eta Eta Eta Eta Et
	支持向量机
	是升方法
	EM 算法及其推广
0	<b>隐马尔可夫模型</b>
•	10 55 57 (AZ
1	条件随机场
_	
	12.1 矩阵
	12.2 优化
	12.2.1 拉格朗日乘子法
	12.2.2 梯度下降
	12.2.3 牛顿法
	12.2.4 拟牛顿法
	12.3. 拉格朗日对倮性

## 1 概述

## 1.1 统计学习三要素

## 1.1.1 模型

监督学习中,模型是要学习的条件概率分布或决策函数。

#### 1.1.1.1 模型的假设空间

假设空间是所有可能的条件概率分布或决策函数

#### 1.1.1.1.1 定义 1

可以定义为决策函数的集合:

$$\mathcal{F} = \{ f | Y = f(X) \}$$

- X 和 Y 是定义在  $\mathcal{X}$  和  $\mathcal{Y}$  上的变量
- $\mathcal{F}$  是一个参数向量决定的函数族:

$$\mathcal{F} = \{ f | Y = f_{\theta}(X), \theta \in \mathbb{R}^n \}$$

参数向量  $\theta$  取值于 n 维欧式空间  $R^n$  , 称为参数空间

## 1.1.1.1.2 定义 2

也可以定义为条件概率的集合:

$$\mathcal{F} = \{P|P(Y|X)\}$$

- X 和 Y 是定义在  $\mathcal{X}$  和  $\mathcal{Y}$  上的随机变量
- $\mathcal{F}$  是一个参数向量决定的条件概率分布族:

$$\mathcal{F} = \{P|P_{\theta}(Y|X), \theta \in \mathbb{R}^n\}$$

#### 1.1.2 策略

#### 1.1.2.1 损失函数与风险函数

损失函数(loss function)或代价函数(cost function): 度量预测值 f(X) 与真实值 Y 的误差程度,记为 L(Y,f(X)),是个非负实值函数。损失函数越小,模型越好。

• 0-1 损失函数:

$$L(Y, f(X)) = \begin{cases} 0 & Y \neq f(X) \\ 1 & Y = f(X) \end{cases}$$

• 平方损失函数:

$$L(Y, f(X)) = (Y - f(X))^2$$

• 绝对损失函数:

$$L(Y, f(x)) = |Y - f(X)|$$

• 对数损失函数 (logarithmic loss function)/对数似然损失函数 (log-likelihood loss function):

$$L(Y, P(Y|X)) = -logP(Y|X)$$

风险函数 (risk function) 或期望损失 (expected loss) : X 和 Y 服从联合分布 P(X,Y) , 理论上模型 f(X) 关于联合分布 P(X,Y) 的平均意义下的损失 :

$$R_{exp}(f) = E_P[L(Y, f(X))] = \int_{\mathcal{X} \times \mathcal{Y}} L(y, f(x)) P(x, y) dx dy$$

学习的目标:选择期望风险最小的模型。但联合分布 P(X,Y) 是未知的,所以无法直接计算  $R_{exp}(f)$ 。所以监督学习是病态问题 ( ill-formed problem ):一方面需要联合分布,另一方面联合分布是未知的。

给定训练集:

$$T = \{(x_1, y_1), ...(x_N, y_N)\}\$$

经验风险 (expirical risk)/经验损失 (expirical loss) : 模型 f(X) 关于训练集的平均损失

$$R_{emp}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i))$$

根据大数定律,当样本容量 N 趋向无穷时,经验风险  $R_{emp}$  趋于期望风险  $R_{exp}(f)$ 。

#### 1.1.2.2 经验风险最小化与结构风险最小化

经验风险最小化(empirical risk minimization, ERM):经验风险最小的模型就是最优模型。所以需要求解的最优化问题是:

$$min_{f \in \mathcal{F}} R_{erm} = min_{f \in \mathcal{F}} \frac{1}{N} L(y_i, f(x_i))$$

当满足以下两个条件时,经验风险最小化就等价于极大似然估计(maximum likelihood estimation):

- 模型是条件概率分布
- 损失函数是对数损失函数

当样本量足够大时, ERM 能有很好的效果, 但样本量不够多时, 为了防止过拟合, 需要用下面的方法。

结构风险最小化(structual risk minimization, SRM):结构风险 = 经验风险 + 表示模型复杂度的正则化项 (regularizer) 或罚项 (penalty term)。结构风险定义如下:

$$R_{srm}(f) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

J(f) 是模型的复杂度,模型越复杂,J(f) 越大。 $\lambda \geq 0$  是用于权衡经验风险和模型复杂度的系数。

当满足以下 3 个条件时,结构化风险最小化等价于) 贝叶斯估计中的最大后验概率估计 (maximum posterior probability estimation, MAP):

- 模型是条件概率分布
- 损失函数是对数损失函数
- 模型复杂度由模型的先验概率表示

所以结构风险最小化就是求解优化问题:

$$min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^{N} L(y_i, f(x_i)) + \lambda J(f)$$

## 1.1.3 算法

算法指的是学习模型的具体方法,即使用什么计算方法求解最优模型。

因为统计学习问题归结为最优化问题,所以统计学习的算法就是求解最优化问题的算法。

- 如果有显式的解析解,此最优化问题就比较简单
- 如果没有,需要用数值计算方法求解,需要考虑如何保证找到全局最优解,并使求解过程高效

- 1.2 模型评估与模型选择
- 1.2.1 训练误差与测试误差
- 1.2.2 过拟合与模型选择
- 1.3 正则化与交叉验证
- 1.3.1 正则化
- 1.3.2 交叉验证
- 1.4 泛化能力
- 1.4.1 泛化误差
- 1.4.2 泛化误差上界
- 1.5 生成模型与判别模型
- 1.6 分类问题
- 1.7 标注问题
- 1.8 回归问题
- 2 感知机
- 3 k 近邻法
- 4 朴素贝叶斯法
- 5 决策树
- 6 logistic 回归与最大熵模型
- 7 支持向量机
- 8 提升方法
- 9 EM 算法及其推广
- 10 隐马尔可夫模型
- 11 条件随机场
- 12 附录